

① Model

Layer	kernel(k) stride (S) padding(P)	height-in (h=w)	height-out (h-out)	Channel-in (C-in)	Channel-out (C-out)	
Conv	$k=7, S=2, P=3$	h_{in}	$h_{in}/2$	3	32	(1)
Max Pool	3, 2, 1	$h_{in}/2$	$h_{in}/4$	32	32	(2)
Conv	5, 1, 2	$h_{in}/4$	$h_{in}/4$	32	64	(3)
Conv	3, 2, 1	$h_{in}/4$	$h_{in}/8$	64	128	(4)
Conv	1, 1, 0	$h_{in}/8$	$h_{in}/8$	128	256	(5)
Conv	3, 2, 1	$h_{in}/8$	$h_{in}/16$	256	256	(6)
Conv	1, 1, 0	$h_{in}/16$	$h_{in}/16$	256	512	(7)
Global Avg Pool		$h_{in}/16$	1	512	512	(8)
Linear				512	256	(9)
Relu				256	256	(10)
Linear				256	100	(11)

② $M_1 \times M_2 \sim 2nmp$, $n = B \cdot H_{out}^2$ (B-Batch-size)
 $(n \times p) \quad (p \times m)$ $m = k^2 \cdot C_{in}$ (k-kernel)
 $p = C_{out}$

Flops (conv):

$$2nmp = 2 \cdot B \cdot H_{out}^2 \cdot k^2 \cdot C_{in} \cdot C_{out}$$

Del kangoro CONV core:

L	n	m	p	Flops
1	$B \cdot \left(\frac{h \cdot n}{2}\right)^2$	$4^2 \cdot 3$	32	$2352 \cdot B \cdot h \cdot n^2$
2	$B \cdot \left(\frac{h \cdot n}{4}\right)^2$	$3^2 \cdot 3$	32	
3	$B \cdot \left(\frac{h \cdot n}{4}\right)^2$	$5^2 \cdot 32$	64	$8900 \cdot B \cdot h \cdot n^2$
4	$B \cdot \left(\frac{h \cdot n}{8}\right)^2$	$3^2 \cdot 64$	128	$2304 \cdot B \cdot h \cdot n^2$
5	$B \cdot \left(\frac{h \cdot n}{8}\right)^2$	$12 \cdot 128$	256	$1024 \cdot B \cdot h \cdot n^2$
6	$B \cdot \left(\frac{h \cdot n}{16}\right)^2$	$3^2 \cdot 256$	256	$4608 \cdot B \cdot h \cdot n^2$
7	$B \cdot \left(\frac{h \cdot n}{16}\right)^2$	$12 \cdot 256$	512	$1024 \cdot B \cdot h \cdot n^2$
				17712

Flops (Linear), $n=B$, $m=C \cdot n$, $p=C \cdot n$

$$2 \cdot n \cdot m \cdot p = 2 \cdot B \cdot C \cdot n \cdot C \cdot n$$

L	n	m	p	Flops
9	B	512	256	$262144 B$
11	B	256	100	$51200 B$
				313344

Model:

$$Flops(S, B) = B \cdot (17712 \cdot S^2 + 313344)$$

$$\textcircled{3} \text{Memory}(S, B) = W + \text{activations}(S, B)$$

$$C_{in} \cdot C_{out} \cdot k^2$$

- кол-во параметров
BN = 4 · C_{out}

1	32 · 32 · 49 = 4704	128
3	64 · 32 · 25 = 51200	356
4	128 · 64 · 9 = 73728	512
5	256 · 128 · 1 = 32768	1024
6	256 · 256 · 9 = 589824	1024
7	512 · 256 · 1 = 131072	2048

$$h \cdot w$$

Bias

9	512 · 256	256
11	256 · 100	100

$$n\text{-parameters} = 1045316$$

$$\text{memory}(w) = 4 \text{ байта} \cdot n\text{-parameters} \sim 4,18 \text{ MB}$$

Активации:

	C _{out}	H _{out}	Умно в активации (B · C _{out} · (H _{out}) ²) (т.к. h=w)
1	32	3/2	8 · B · 5 ²
2	32	5/4	2 · B · 5 ²
3	64	5/4	4 · B · 5 ²
4	128	5/8	2 · B · 5 ²
5	256	5/8	4 · B · 5 ²
6	256	5/16	1 · B · 5 ²
7	512	5/16	2 · B · 5 ²
8	512	1	512 · B
9	256		256 · B
10	256		256 · B
11	100		100 · B

$$4 \cdot B (26 \cdot 5^2 + 1124)$$

$$\text{Memory}(S, B) = 4,18 \text{ MB} + 4 \cdot B (26 \cdot 5^2 + 1124)$$

④ Bytes Moved

- 1) Когда тензор передается в GPU из предыдущего слоя
- 2) в GPU передается вторичный массив
- 3) в GPU записывается результирующий тензор

Для conv: Read Input = $B \cdot C_{in} \cdot H_{in}^2$

Read Weights = $C_{out} \cdot C_{in} \cdot k^2$

Write Output = $B \cdot C_{out} \cdot H_{out}^2$

	Read Inp	Read Weig	Write Out
1	$3 \cdot B \cdot S^2$	4704	$8 \cdot B \cdot S^2$
2	$2 \cdot B \cdot S^2$	51200	$4 \cdot B \cdot S^2$
3	$4 \cdot B \cdot S^2$	73728	$2 \cdot B \cdot S^2$
4	$2 \cdot B \cdot S^2$	32768	$4 \cdot B \cdot S^2$
5	$4 \cdot B \cdot S^2$	589824	$1 \cdot B \cdot S^2$
6	$1 \cdot B \cdot S^2$	131072	$2 \cdot B \cdot S^2$

$37 \cdot B \cdot S^2 + 883296$

Для Max Pool: Read Input = $B \cdot C_{in} \cdot (H_{in})^2$

Read Weights = 0

Write Output = $B \cdot C_{in} \cdot (H_{out})^2$

$10 \cdot B \cdot S^2$

Для Batch Norm: Read Input = $B \cdot C_{in} \cdot (H_{in})^2$

Read Weights = $4 \cdot C_{in}$

Write Output = $B \cdot C_{in} \cdot (H_{in})^2$

process

70p

	Read Inp	Read Weig	Write Out
1	$8 \cdot B \cdot S^2$	128	$8 \cdot B \cdot S^2$
3	$4 \cdot B \cdot S^2$	256	$4 \cdot B \cdot S^2$
4	$2 \cdot B \cdot S^2$	512	$2 \cdot B \cdot S^2$
5	$4 \cdot B \cdot S^2$	1024	$4 \cdot B \cdot S^2$
6	$1 \cdot B \cdot S^2$	1024	$1 \cdot B \cdot S^2$
7	$2 \cdot B \cdot S^2$	2048	$2 \cdot B \cdot S^2$

$$42 \cdot B \cdot S^2 + 4992$$

Dir Global Avg Pool: $\text{Read Input} = B \cdot C_{in} \cdot (H_{in})^2$
 $\text{Read Weight} = 0$
 $\text{Write Output} = B \cdot C_{in} \cdot (H_{out})^2$
 $2 \cdot B \cdot S^2 + 512 B$

Dir Linear:

	Read Inp	Read Weig	Write Out
9	$B \cdot 512$	131328	$B \cdot 256$
11	$B \cdot 256$	25700	$B \cdot 100$

$$1124 B + 157028$$

Dir ReLU: $\text{Read Input} - \text{Write Output} = B \cdot C_{out} \cdot (H_{out})^2$
 $\text{Read Weight} = 0$

	Read Inp	Read Weig	Write Out
1	$8 \cdot B \cdot S^2$		$8 \cdot B \cdot S^2$
3	$4 \cdot B \cdot S^2$		$4 \cdot B \cdot S^2$
4	$2 \cdot B \cdot S^2$		$2 \cdot B \cdot S^2$
5	$4 \cdot B \cdot S^2$		$4 \cdot B \cdot S^2$
6	$1 \cdot B \cdot S^2$		$1 \cdot B \cdot S^2$
7	$2 \cdot B \cdot S^2$		$2 \cdot B \cdot S^2$
10	$256 B$		$256 B$

$$42 \cdot B \cdot S^2 + 512 \cdot B$$

$$\text{Bytes}(S, B) = 4 \text{ байта} \cdot (133 \cdot B \cdot S^2 + 2148 B \cdot 1045316)$$

⑤ Latency:

Пусто все операции выполняются на одном GPU - conv, BN, ReLU соединены в единую операцию. кол-во запусков kernel;

1) Conv 7×7 + BN + ReLU

2) Max Pool

3) Conv 3×3 + BN + ReLU

4) Conv 3×3 + BN + ReLU

5) Conv 1×1 + BN + ReLU

6) Conv 3×3 + BN + ReLU

7) Conv 1×1 + BN + ReLU

8) Global Avg Pool

9) Linear $512 \rightarrow 256$

10) ReLU

11) Linear $256 \rightarrow 100$

- 11 запусков

• Пусто t-launch (сек) - функ. overhead на запуск одного kernel, не зависит от размера data

• Пусто P-eff (flops/сек) - реальн. пропуск. способность GPU по формуле

5316

- Пусть BW_{eff} (байт/сек) - реальн. пропускная способность памяти GPU
- $Q(t_{launch}, P_{eff}, BW_{eff})$ - калибруется на GPU

$$Latency(S, B, Q) = 11 \cdot t_{launch} + \max\left(\frac{Flops(S, B)}{P_{eff}}, \frac{Bytes(S, B)}{BW_{eff}}\right) =$$

$$= 11 \cdot t_{launch} + \max\left(\frac{B \cdot (17712 \cdot S^2 + 313344)}{P_{eff}}, \frac{4 \cdot (133 \cdot 13 \cdot S^2 + 2148 \cdot B + 1045316)}{BW_{eff}}\right)$$

⑥ $Energy = power \cdot time$

Пусть $P_{idle} \cdot T$ - сколько Вт уходит на работу GPU за время T , независимо от того, что мы считаем.

Пусть $e_{flop} \times Flops$ - гол. энергия за арифметическую операцию

Пусть $e_{byte} \times Bytes$ - энергия на перемещение данных

Q - еще 3 параметра;

P_{idle} - базовая мощность GPU (ватт)

P_{flop} - энергия на одну операцию ($\frac{Вт}{Flop}$)

P_{byte} - энергия на перемещ. 1 байта ($\frac{Вт}{байт}$)

$$Energy = P_{idle} \cdot T + e_{flop} \cdot F + e_{byte} \cdot Bytes$$

$$Energy(S, B) = P_{idle} \cdot (25 \cdot t_{launch} + \max\left(\frac{F}{P_{eff}}, \frac{D}{BW_{eff}}\right) + e_{flop} \cdot B \cdot (17712 \cdot S^2 + 313344) + e_{byte} \cdot (4 \cdot (133 \cdot 13 \cdot S^2 + 2148 \cdot B + 1045316)))$$